


# 数据科学与大数据技术 的数学基础



## 第八讲



计算机学院

余皓然

2024/5/13

# 课程内容

---

## Part1 随机化方法

一致性哈希 布隆过滤器 CM Sketch方法 最小哈希  
欧氏距离下的相似搜索 Jaccard相似度下的相似搜索

## Part2 谱分析方法

主成分分析 奇异值分解 谱图论

## Part3 最优化方法

压缩感知



# 主成分分析

## 主成分的代数性质



# 代数分析

## 主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$

如何进一步用线性代数工具改写问题 (如写成矩阵/向量相乘形式) ?



# 代数分析

## 主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$


如何进一步用线性代数工具改写问题（如写成矩阵/向量相乘形式）？

先分析  $k = 1$  的情况（科研中常用思路：先分析简化问题、寻找规则，再求拓展）




## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ ，求单位向量  $v \in \mathbb{R}^n$  从而最大化  $\frac{1}{m} \sum_{i=1}^m \langle x_i, v \rangle^2$ 。



## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ ，求单位向量  $v \in \mathbb{R}^n$  从而最大化  $\frac{1}{m} \sum_{i=1}^m \langle x_i, v \rangle^2$ 。



## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ , 求单位向量  $v \in \mathbb{R}^n$  从而最大化  $\frac{1}{m} \sum_{i=1}^m \langle x_i, v \rangle^2$ .




Diagram illustrating the sum of squares of inner products.

A row of green rectangles representing  $\langle x_1, v \rangle, \langle x_2, v \rangle, \dots, \langle x_m, v \rangle$  is shown, enclosed in a dashed box.

Below this row, the expression  $\langle x_1, v \rangle \langle x_2, v \rangle \langle x_m, v \rangle$  is shown.

To the right, a column of green rectangles representing  $\langle x_1, v \rangle, \langle x_2, v \rangle, \dots, \langle x_m, v \rangle$  is shown, enclosed in a dashed box.

To the right of this column, the expression  $\langle x_1, v \rangle, \langle x_2, v \rangle, \dots, \langle x_m, v \rangle$  is shown.

Further right, the expression  $= \sum_{i=1}^m \langle x_i, v \rangle^2$  is shown.



## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ , 求单位向量  $v \in \mathbb{R}^n$  从而最大化  $\frac{1}{m} \sum_{i=1}^m \langle x_i, v \rangle^2$ .

$x_1^T$   $x_2^T$   $\dots$   $x_m^T$

$m \times n$  矩阵  $X$

$=$

$\langle x_1, v \rangle$   
 $\langle x_2, v \rangle$   
 $\dots$   
 $\langle x_m, v \rangle$

$(Xv)^T$

$n \times 1$  向量  $v$

$= \sum_{i=1}^m \langle x_i, v \rangle^2$

## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ , 求单位向量  $v \in \mathbb{R}^n$  从而最大化  $\frac{1}{m} \sum_{i=1}^m \langle x_i, v \rangle^2$ .

$$\begin{matrix} x_1^T \\ x_2^T \\ \vdots \\ x_m^T \end{matrix} \begin{matrix} \text{orange rectangles} \end{matrix} \quad \begin{matrix} \text{blue rectangle} \end{matrix} = \begin{matrix} \text{green rectangles} \\ \langle x_1, v \rangle \\ \langle x_2, v \rangle \\ \vdots \\ \langle x_m, v \rangle \end{matrix}$$

$m \times n$  矩阵  $X$

$n \times 1$  向量  $v$

$$(Xv)^T (Xv) = \sum_{i=1}^m \langle x_i, v \rangle^2$$

## $k = 1$ 情况

---

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ , 求单位向量  $\mathbf{v} \in \mathbb{R}^n$  从而最大化  $\mathbf{v}^T \mathbf{X}^T \mathbf{X} \mathbf{v}$ .

略去系数  $\frac{1}{m}$


分析  $n \times n$  矩阵  $\mathbf{X}^T \mathbf{X}$  是对称矩阵, 因为  $(\mathbf{X}^T \mathbf{X})^T = \mathbf{X}^T \mathbf{X}$



## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ ，求单位向量  $v \in \mathbb{R}^n$  从而最大化  $v^T X^T X v$ 。


分析  $n \times n$  矩阵  $X^T X$  是对称矩阵，因为  $(X^T X)^T = X^T X$



## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ ，求单位向量  $v \in \mathbb{R}^n$  从而最大化  $v^T X^T X v$ .

分析  $n \times n$  矩阵  $X^T X$  是对称矩阵，因为  $(X^T X)^T = X^T X$




假设每个数据  $x_i$  对应一个文件  $i$  而且  $x_{ij}$  表示编号为  $j$  的词出现情况  
矩阵  $X^T X$  的  $(l, h)$  元素的含义?

## $k = 1$ 情况

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ ，求单位向量  $v \in \mathbb{R}^n$  从而最大化  $v^T X^T X v$ .

分析  $n \times n$  矩阵  $X^T X$  是对称矩阵，因为  $(X^T X)^T = X^T X$



假设每个数据  $x_i$  对应一个文件  $i$  而且  $x_{ij}$  表示编号为  $j$  的词出现情况

矩阵  $X^T X$  的  $(l, h)$  元素的含义：有多少次编号为  $l$  的词与编号为  $h$  的词同时在一个文件中出现过

## $k = 1$ 情况

---

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ ，求单位向量  $\mathbf{v} \in \mathbb{R}^n$  从而最大化  $\mathbf{v}^T \mathbf{X}^T \mathbf{X} \mathbf{v}$ .

将  $n \times n$  矩阵  $\mathbf{X}^T \mathbf{X}$  称为（预处理后的）向量  $\mathbf{x}_1, \dots, \mathbf{x}_m$  的协方差矩阵

为书写方便，记矩阵  $\mathbf{X}^T \mathbf{X}$  为矩阵  $\mathbf{A}$

先分析如何在特殊情况选择单位向量  $\mathbf{v}$  最大化  $\mathbf{v}^T \mathbf{A} \mathbf{v}$



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

---

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$





## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\text{易得 } v^T \mathbf{A} v = (v_1 \lambda_1, v_2 \lambda_2, \dots, v_n \lambda_n) \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix} = \sum_{i=1}^n v_i^2 \lambda_i$$

问题简化为:

$$\begin{aligned} \max & \sum_{i=1}^n v_i^2 \lambda_i \\ \text{s. t.} & \sum_{i=1}^n v_i^2 = 1 \end{aligned}$$



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 是对角矩阵

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$$

且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\text{易得 } v^T \mathbf{A} v = (v_1 \lambda_1, v_2 \lambda_2, \dots, v_n \lambda_n) \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix} = \sum_{i=1}^n v_i^2 \lambda_i$$

问题简化为:

$$\begin{aligned} \max \quad & \sum_{i=1}^n v_i^2 \lambda_i \\ \text{s. t.} \quad & \sum_{i=1}^n v_i^2 = 1 \end{aligned}$$

解为  $v^* = (1, 0, \dots, 0)$  或  $(-1, 0, \dots, 0)$

(通过将  $v_i^2$  换成非负变量易得)

下一步: 拓展到更一般化的 $\mathbf{A}$



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵  
满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

$$\text{例: } \begin{bmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

$\mathbf{A} \qquad \mathbf{Q} \qquad \mathbf{D} \qquad \mathbf{Q}^T$

正交矩阵即所有列向量构成**标准正交向量组** (列向量模都为1且彼此内积为0) 的 (实数) **方阵**



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵  
满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

$$\text{例: } \begin{bmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

$\mathbf{A} \qquad \mathbf{Q} \qquad \mathbf{D} \qquad \mathbf{Q}^T$

$$\begin{aligned} I &= BB^{-1} = BIB^{-1} \\ &= B(AB)B^{-1} && \text{since } AB = I \\ &= BAI = BA. \end{aligned}$$

正交矩阵即所有列向量构成**标准正交向量组** (列向量模都为1且彼此内积为0) 的 (实数) **方阵**

- 有 $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$  (展开矩阵、利用标准正交向量定义可得)
- 有 $\mathbf{Q} \mathbf{Q}^T = \mathbf{I}$  (由 $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ 及逆矩阵性质可得)
- $\det(\mathbf{Q}) = 1 \text{ or } -1$  (利用 $\det(\mathbf{Q}^T) \det(\mathbf{Q}) = \det(\mathbf{Q})^2 = \det(\mathbf{I}) = 1$ 得)
- $\mathbf{Q}$ 的行向量也构成标准正交向量组, 即 $\mathbf{Q}^T$ 也是正交矩阵 (由 $\mathbf{Q} \mathbf{Q}^T = \mathbf{I}$ 及标准正交向量组定义得)
- 对任意 $n \times 1$ 向量 $v$ 有 $\|\mathbf{Q}v\|^2 = \|v\|^2$  (由 $\|\mathbf{Q}v\|^2 = (\mathbf{Q}v)^T \mathbf{Q}v$ 以及 $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ 可得)

## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵  
满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

$$\text{例: } \begin{bmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

$\mathbf{A} \qquad \mathbf{Q} \qquad \mathbf{D} \qquad \mathbf{Q}^T$

正交矩阵即所有列向量构成**标准正交向量组** (列向量模都为1且彼此内积为0) 的 (实数) **方阵**

- 有 $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$  (展开矩阵、利用标准正交向量定义可得)
- 有 $\mathbf{Q} \mathbf{Q}^T = \mathbf{I}$  (由 $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ 及逆矩阵性质可得)
- $\det(\mathbf{Q}) = 1$  or  $-1$  (利用 $\det(\mathbf{Q}^T) \det(\mathbf{Q}) = \det(\mathbf{Q})^2 = \det(\mathbf{I}) = 1$ 得)
- $\mathbf{Q}$ 的行向量也构成标准正交向量组, 即 $\mathbf{Q}^T$ 也是正交矩阵 (由 $\mathbf{Q} \mathbf{Q}^T = \mathbf{I}$ 及标准正交向量组定义得)
- 对任意 $n \times 1$ 向量 $v$ 有 $\|\mathbf{Q}v\|^2 = \|v\|^2$  (由 $\|\mathbf{Q}v\|^2 = (\mathbf{Q}v)^T \mathbf{Q}v$ 以及 $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ 可得)

求解  $\max_{\|v\|=1} v^T \mathbf{QDQ}^T v$

## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵

满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

可将 $v^T \mathbf{QDQ}^T v$ 整理为 $\sum_{i=1}^n \lambda_i (v^T q_i)^2$  (通过将矩阵 $\mathbf{Q}$ 展成 $[q_1, q_2, \dots, q_n]$ )



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵  
满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

可将 $v^T \mathbf{QDQ}^T v$ 整理为 $\sum_{i=1}^n \lambda_i (v^T q_i)^2$  (通过将矩阵 $\mathbf{Q}$ 展成 $[q_1, q_2, \dots, q_n]$ )

目标函数简化为:

$$\max \sum_{i=1}^n \lambda_i (v^T q_i)^2$$

约束条件整理为:

$$\text{s. t. } \sum_{i=1}^n (v^T q_i)^2 = \underbrace{\|v^T \mathbf{Q}\|^2}_{= \|v\|^2} = 1$$

$\mathbf{Q}^T$ 是正交矩阵时有 $\|Q^T v\|^2 = \|v\|^2$



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵  
满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

可将 $v^T \mathbf{QDQ}^T v$ 整理为 $\sum_{i=1}^n \lambda_i (v^T q_i)^2$  (通过将矩阵 $\mathbf{Q}$ 展成 $[q_1, q_2, \dots, q_n]$ )

目标函数简化为:

$$\max \sum_{i=1}^n \lambda_i (v^T q_i)^2$$

约束条件整理为:

$$\text{s. t. } \sum_{i=1}^n (v^T q_i)^2 = 1$$

前述 $\mathbf{A}$ 为对角矩阵时的结果

$$\begin{aligned} & \max \sum_{i=1}^n \lambda_i v_i^2 \\ & \text{s. t. } \sum_{i=1}^n v_i^2 = 1 \end{aligned}$$

$$v^* = (1, 0, \dots, 0) \text{ 或 } (-1, 0, \dots, 0)$$





## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|v\|=1} v^T \mathbf{A} v$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵  
满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

可将 $v^T \mathbf{QDQ}^T v$ 整理为 $\sum_{i=1}^n \lambda_i (v^T q_i)^2$  (通过将矩阵 $\mathbf{Q}$ 展成 $[q_1, q_2, \dots, q_n]$ )

目标函数简化为:

$$\max \sum_{i=1}^n \lambda_i (v^T q_i)^2$$

约束条件整理为:

$$\text{s. t. } \sum_{i=1}^n (v^T q_i)^2 = 1$$

(最优解之一)

$v^*$ 使 $v^T [q_1, q_2, \dots, q_n] = (1, 0, \dots, 0)$

前述 $\mathbf{A}$ 为对角矩阵时的结果

$$\begin{aligned} & \max \sum_{i=1}^n \lambda_i v_i^2 \\ & \text{s. t. } \sum_{i=1}^n v_i^2 = 1 \end{aligned}$$

$v^* = (1, 0, \dots, 0)$  或  $(-1, 0, \dots, 0)$



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

$$\max_{\|\mathbf{v}\|=1} \mathbf{v}^T \mathbf{A} \mathbf{v}$$

假设 $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ , 其中 $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是对角矩阵  
满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \text{ 且}$$

可将 $\mathbf{v}^T \mathbf{QDQ}^T \mathbf{v}$ 整理为 $\sum_{i=1}^n \lambda_i (\mathbf{v}^T \mathbf{q}_i)^2$  (通过将矩阵 $\mathbf{Q}$ 展成 $[\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n]$ )

目标函数简化为:

$$\max \sum_{i=1}^n \lambda_i (\mathbf{v}^T \mathbf{q}_i)^2$$

约束条件整理为:

$$\text{s. t. } \sum_{i=1}^n (\mathbf{v}^T \mathbf{q}_i)^2 = 1$$

(最优解之一)

$\mathbf{v}^*$ 使 $\mathbf{v}^T [\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n] = (1, 0, \dots, 0)$

解为 $\mathbf{v}^* = \mathbf{q}_1$  (矩阵 $\mathbf{Q}$ 的第一列)

前述 $\mathbf{A}$ 为对角矩阵时的结果

$$\begin{aligned} & \max \sum_{i=1}^n \lambda_i v_i^2 \\ & \text{s. t. } \sum_{i=1}^n v_i^2 = 1 \end{aligned}$$

$\mathbf{v}^* = (1, 0, \dots, 0)$  或  $(-1, 0, \dots, 0)$

如果所有的 $\mathbf{A}$ 都可写成 $\mathbf{QDQ}^T$ 的形式、 $\mathbf{Q}$ 和 $\mathbf{D}$ 满足前述条件, 即可完成对 $k = 1$ 时的分析

## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

---

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$


## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

$$\begin{bmatrix} | & | \\ \mathbf{q}_1 & \mathbf{q}_2 \\ | & | \end{bmatrix} \quad \begin{bmatrix} | \\ \mathbf{q}_n \\ | \end{bmatrix} \quad \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \begin{bmatrix} \text{---} \mathbf{q}_1^T \text{---} \\ \text{---} \mathbf{q}_2^T \text{---} \\ \vdots \\ \text{---} \mathbf{q}_n^T \text{---} \end{bmatrix}$$



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

易由特征向量及特征值定义得 (如证 $\mathbf{A}\mathbf{p}_1 = \mathbf{PDP}^T\mathbf{p}_1 = \lambda_1\mathbf{p}_1$ ) :

$\mathbf{P}$ 的列向量为 $\mathbf{A}$ 的特征向量、 $\mathbf{D}$ 的对角线元素为 $\mathbf{A}$ 的特征值



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

易由特征向量及特征值定义得 (如证 $\mathbf{A}\mathbf{p}_1 = \mathbf{PDP}^T\mathbf{p}_1 = \lambda_1\mathbf{p}_1$ ) :

$\mathbf{P}$ 的列向量为 $\mathbf{A}$ 的特征向量、 $\mathbf{D}$ 的对角线元素为 $\mathbf{A}$ 的特征值

还需要对角矩阵 $\mathbf{D}$ 的元素全为非负且按大小排列



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

易由特征向量及特征值定义得 (如证 $\mathbf{A}\mathbf{p}_1 = \mathbf{PDP}^T\mathbf{p}_1 = \lambda_1\mathbf{p}_1$ ) :

$\mathbf{P}$ 的列向量为 $\mathbf{A}$ 的特征向量、 $\mathbf{D}$ 的对角线元素为 $\mathbf{A}$ 的特征值

还需要对角矩阵 $\mathbf{D}$ 的元素全为非负且按大小排列

证明对称矩阵 $\mathbf{X}^T \mathbf{X}$ 是半正定矩阵, 即对任意向量 $\mathbf{u} \in \mathbb{R}^n$ 有 $\mathbf{u}^T \mathbf{X}^T \mathbf{X} \mathbf{u} \geq 0$ 。

再利用半正定矩阵的所有特征值非负的性质证明对角矩阵 $\mathbf{D}$ 的元素全为非负。

## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

易由特征向量及特征值定义得 (如证 $\mathbf{A}\mathbf{p}_1 = \mathbf{PDP}^T\mathbf{p}_1 = \lambda_1\mathbf{p}_1$ ) :

$\mathbf{P}$ 的列向量为 $\mathbf{A}$ 的特征向量、 $\mathbf{D}$ 的对角线元素为 $\mathbf{A}$ 的特征值

还需要对角矩阵 $\mathbf{D}$ 的元素全为非负且按大小排列

证明对称矩阵 $\mathbf{X}^T \mathbf{X}$ 是半正定矩阵, 即对任意向量 $\mathbf{u} \in \mathbb{R}^n$ 有 $\mathbf{u}^T \mathbf{X}^T \mathbf{X} \mathbf{u} \geq 0$ 。

也可取 $\mathbf{u} = \mathbf{p}_i$  ( $\mathbf{P}$ 的第 $i$ 列向量) 此时 $\mathbf{u}^T \mathbf{X}^T \mathbf{X} \mathbf{u} = \mathbf{p}_i^T \lambda_i \mathbf{p}_i = \lambda_i$  (利用标准正交向量性质或特征向量定义), 说明对所有特征值有 $\lambda_i \geq 0$ 。



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

易由特征向量及特征值定义得 (如证 $\mathbf{A}\mathbf{p}_1 = \mathbf{PDP}^T\mathbf{p}_1 = \lambda_1\mathbf{p}_1$ ) :

$\mathbf{P}$ 的列向量为 $\mathbf{A}$ 的特征向量、 $\mathbf{D}$ 的对角线元素为 $\mathbf{A}$ 的特征值

还需要对角矩阵 $\mathbf{D}$ 的元素按大小排列



## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

易由特征向量及特征值定义得 (如证 $\mathbf{A}\mathbf{p}_1 = \mathbf{PDP}^T \mathbf{p}_1 = \lambda_1 \mathbf{p}_1$ ) :

$\mathbf{P}$ 的列向量为 $\mathbf{A}$ 的特征向量、 $\mathbf{D}$ 的对角线元素为 $\mathbf{A}$ 的特征值

还需要对角矩阵 $\mathbf{D}$ 的元素按大小排列

同时调整特征值及相应特征向量的排序, 结果不变

$$\begin{bmatrix} | & | & & | \\ \mathbf{q}_1 & \mathbf{q}_2 & & \mathbf{q}_n \\ | & | & & | \end{bmatrix} \quad \begin{bmatrix} | \\ \mathbf{q}_n \\ | \end{bmatrix} \quad \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \begin{bmatrix} \text{---} \mathbf{q}_1^T \text{---} \\ \text{---} \mathbf{q}_2^T \text{---} \\ \vdots \\ \text{---} \mathbf{q}_n^T \text{---} \end{bmatrix}$$

## $k = 1$ 情况: $\mathbf{A}$ 满足特殊条件

对 $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ , 是否总可写成 $\mathbf{QDQ}^T$ ?  $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$\mathbf{A} = \mathbf{X}^T \mathbf{X}$ 是对称矩阵

### 线性代数知识

实对称矩阵的正交对角化 (Orthogonal Diagonalization of Real Symmetric Matrices)

若 $\mathbf{A}$ 是实对称矩阵, 存在正交矩阵 $\mathbf{P}$ 和对角矩阵 $\mathbf{D}$ 使 $\mathbf{A} = \mathbf{PDP}^T$ 。

易由特征向量及特征值定义得 (如证 $\mathbf{A}\mathbf{p}_1 = \mathbf{PDP}^T\mathbf{p}_1 = \lambda_1\mathbf{p}_1$ ) :

$\mathbf{P}$ 的列向量为 $\mathbf{A}$ 的特征向量、 $\mathbf{D}$ 的对角线元素为 $\mathbf{A}$ 的特征值

还需要对角矩阵 $\mathbf{D}$ 的元素按大小排列

例如, 
$$[\mathbf{p}_1, \mathbf{p}_2] \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \begin{bmatrix} \mathbf{p}_1^T \\ \mathbf{p}_2^T \end{bmatrix} = [\mathbf{p}_2, \mathbf{p}_1] \begin{bmatrix} \lambda_2 & 0 \\ 0 & \lambda_1 \end{bmatrix} \begin{bmatrix} \mathbf{p}_2^T \\ \mathbf{p}_1^T \end{bmatrix}$$

## $k = 1$ 情况

回顾

$$\max \sum_{i=1}^n \lambda_i (\mathbf{v}^T \mathbf{q}_i)^2 \quad \text{s. t. } \sum_{i=1}^n (\mathbf{v}^T \mathbf{q}_i)^2 = 1$$

最优解之一为  $\mathbf{v}^* = \mathbf{q}_1$  (矩阵  $\mathbf{Q}$  的第一列)

### 主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$

### 主成分分析问题的最优解

当  $k = 1$ , 最大化目标函数的向量  $\mathbf{v}^*$  为矩阵  $\mathbf{X}^T \mathbf{X}$  的最大特征值对应的 **单位** 特征向量。

如果在对  $\mathbf{X}^T \mathbf{X}$  做正交对角化时将  $\mathbf{X}^T \mathbf{X}$  最大特征值排在对角矩阵的第一位, 那么  $\mathbf{v}^*$  是正交矩阵的第一个列向量。



## $k = 1$ 情况

主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$

主成分分析问题的最优解

当  $k = 1$ , 最大化目标函数的向量  $\mathbf{v}^*$  为矩阵  $\mathbf{X}^T \mathbf{X}$  的最大特征值对应的单位特征向量。

如果在对  $\mathbf{X}^T \mathbf{X}$  做正交对角化时将  $\mathbf{X}^T \mathbf{X}$  最大特征值排在对角矩阵的第一位, 那么  $\mathbf{v}^*$  是正交矩阵的第一个列向量。

如何推广到  $k \geq 2$  的情况?

## $k = 2$ 情况

---

给定  $x_1, \dots, x_m \in \mathbb{R}^n$ , 求标准正交向量  $v_1, v_2 \in \mathbb{R}^n$  最大化  $\frac{1}{m} \sum_{i=1}^m (\langle x_i, v_1 \rangle^2 + \langle x_i, v_2 \rangle^2)$ .



## $k = 2$ 情况

---

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ ，求标准正交向量  $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^n$  最大化  $\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \langle \mathbf{x}_i, \mathbf{v}_2 \rangle^2)$ 。

目标函数改写为（略去  $\frac{1}{m}$ ）： $\mathbf{v}_1^T \mathbf{X}^T \mathbf{X} \mathbf{v}_1 + \mathbf{v}_2^T \mathbf{X}^T \mathbf{X} \mathbf{v}_2$ 。



## $k = 2$ 情况

---

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ ，求标准正交向量  $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^n$  最大化  $\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \langle \mathbf{x}_i, \mathbf{v}_2 \rangle^2)$ 。

目标函数改写为（略去  $\frac{1}{m}$ ）： $\mathbf{v}_1^T \mathbf{X}^T \mathbf{X} \mathbf{v}_1 + \mathbf{v}_2^T \mathbf{X}^T \mathbf{X} \mathbf{v}_2$ 。

考虑特殊情况： $\mathbf{X}^T \mathbf{X}$  是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$





## $k = 2$ 情况

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ ，求标准正交向量  $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^n$  最大化  $\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \langle \mathbf{x}_i, \mathbf{v}_2 \rangle^2)$ 。

目标函数改写为（略去  $\frac{1}{m}$ ）： $\mathbf{v}_1^T \mathbf{X}^T \mathbf{X} \mathbf{v}_1 + \mathbf{v}_2^T \mathbf{X}^T \mathbf{X} \mathbf{v}_2$ 。

考虑特殊情况： $\mathbf{X}^T \mathbf{X}$  是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

问题简化为：

$$\begin{aligned} \max \quad & \sum_{i=1}^n (v_{1i}^2 + v_{2i}^2) \lambda_i \\ \text{s. t.} \quad & \sum_{i=1}^n v_{1i}^2 = 1, \sum_{i=1}^n v_{2i}^2 = 1. \end{aligned}$$



## $k = 2$ 情况

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ ，求标准正交向量  $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^n$  最大化  $\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \langle \mathbf{x}_i, \mathbf{v}_2 \rangle^2)$ 。

目标函数改写为（略去  $\frac{1}{m}$ ）： $\mathbf{v}_1^T \mathbf{X}^T \mathbf{X} \mathbf{v}_1 + \mathbf{v}_2^T \mathbf{X}^T \mathbf{X} \mathbf{v}_2$ 。

考虑特殊情况： $\mathbf{X}^T \mathbf{X}$  是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

问题简化为：

$$\begin{aligned} \max \quad & \sum_{i=1}^n (v_{1i}^2 + v_{2i}^2) \lambda_i \\ \text{s. t.} \quad & \sum_{i=1}^n v_{1i}^2 = 1, \sum_{i=1}^n v_{2i}^2 = 1, \sum_{i=1}^n v_{1i} v_{2i} = 0. \end{aligned}$$

## $k = 2$ 情况

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ ，求标准正交向量  $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^n$  最大化  $\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \langle \mathbf{x}_i, \mathbf{v}_2 \rangle^2)$ 。

目标函数改写为（略去  $\frac{1}{m}$ ）： $\mathbf{v}_1^T \mathbf{X}^T \mathbf{X} \mathbf{v}_1 + \mathbf{v}_2^T \mathbf{X}^T \mathbf{X} \mathbf{v}_2$ 。

考虑特殊情况： $\mathbf{X}^T \mathbf{X}$  是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

问题简化为：

$$\begin{aligned} \max \quad & \sum_{i=1}^n (v_{1i}^2 + v_{2i}^2) \lambda_i \\ \text{s. t.} \quad & \sum_{i=1}^n v_{1i}^2 = 1, \sum_{i=1}^n v_{2i}^2 = 1, \sum_{i=1}^n v_{1i} v_{2i} = 0. \end{aligned}$$

最优解之一为  $\mathbf{v}_1^* = (1, 0, \dots, 0)$ ,  $\mathbf{v}_2^* = (0, 1, \dots, 0)$

当  $\lambda_i$  都不同时，可先证明  $\mathbf{v}_1^*$  和  $\mathbf{v}_2^*$  满足：

$$\exists j, (v_{1j}^*)^2 = 1 \text{ 且 } v_{1i}^* = 0, \forall i \neq j; \exists k \neq j, (v_{2k}^*)^2 = 1 \text{ 且 } v_{2i}^* = 0, \forall i \neq k$$

（用拉格朗日乘子法可证）

# 一般情况

## 主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$

## 主成分分析问题的最优解

最大化目标函数的  $\mathbf{v}_1^*, \dots, \mathbf{v}_k^*$  为矩阵  $\mathbf{X}^T \mathbf{X}$  的最大的  $k$  个特征值对应的  $k$  个单位特征向量。

如果在对  $\mathbf{X}^T \mathbf{X}$  做正交对角化时将  $\mathbf{X}^T \mathbf{X}$  的特征值在对角矩阵中按序排列, 那么  $\mathbf{v}_1^*, \dots, \mathbf{v}_k^*$  是正交矩阵的前  $k$  个列向量。

(一些材料直接将主成分定义为  $\mathbf{X}^T \mathbf{X}$  的最大的  $k$  个特征值对应的单位特征向量。根据以上分析, 这  $k$  个单位特征向量其实对应一个最优化问题的最优解)

# 一般情况

## 主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$

## 主成分分析问题的最优解

最大化目标函数的  $\mathbf{v}_1^*, \dots, \mathbf{v}_k^*$  为矩阵  $\mathbf{X}^T \mathbf{X}$  的最大的  $k$  个特征值对应的  $k$  个单位特征向量。

因为单位特征向量不唯一 (如当  $\lambda_1 = \lambda_2$  时...),  $\mathbf{v}_1^*, \dots, \mathbf{v}_k^*$  不唯一



# 近似误差

## 主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$

## 主成分分析问题的最优解

最大化目标函数的  $\mathbf{v}_1^*, \dots, \mathbf{v}_k^*$  为矩阵  $\mathbf{X}^T \mathbf{X}$  的最大的  $k$  个特征值对应的  $k$  个单位特征向量。




当  $k < n$  时, 如何刻画近似误差? 如何定义? 如何计算?

# 近似误差

## 上一讲内容回顾

将（已完成预处理的） $m$ 个 $n$ 维向量 $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ 近似为 $\sum_{j=1}^k a_{ij} \mathbf{v}_j, i = 1, \dots, m$ 。




$$\operatorname{argmin} \frac{1}{m} \sum_{i=1}^m (\text{distance between } \mathbf{x}_i \text{ and } k\text{-dimensional subspace spanned by } \mathbf{v}_1, \dots, \mathbf{v}_k)^2$$

$$\operatorname{argmax} \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

# 近似误差

上一讲内容回顾

将（已完成预处理的） $m$ 个 $n$ 维向量 $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ 近似为 $\sum_{j=1}^k a_{ij} \mathbf{v}_j, i = 1, \dots, m$ 。



$$\operatorname{argmin} \frac{1}{m} \sum_{i=1}^m (\text{distance between } \mathbf{x}_i \text{ and } k\text{-dimensional subspace spanned by } \mathbf{v}_1, \dots, \mathbf{v}_k)^2$$

$$\operatorname{argmax} \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

本讲中的目标函数


最初问题：  
最小化近似误差



# 近似误差

上一讲内容回顾

将（已完成预处理的） $m$ 个 $n$ 维向量 $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ 近似为 $\sum_{j=1}^k a_{ij} \mathbf{v}_j, i = 1, \dots, m$ 。



$$\operatorname{argmin} \frac{1}{m} \sum_{i=1}^m (\text{distance between } \mathbf{x}_i \text{ and } k\text{-dimensional subspace spanned by } \mathbf{v}_1, \dots, \mathbf{v}_k)^2$$

最初问题：  
最小化近似误差

$$\operatorname{argmax} \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2) \quad \text{本讲中的目标函数}$$


近似误差

$$\frac{1}{m} \sum_{i=1}^m (\text{distance between } \mathbf{x}_i \text{ and } k\text{-dimensional subspace spanned by } \mathbf{v}_1, \dots, \mathbf{v}_k)^2$$

# 近似误差

## 上一讲内容回顾

将（已完成预处理的） $m$ 个 $n$ 维向量 $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$ 近似为 $\sum_{j=1}^k a_{ij} \mathbf{v}_j, i = 1, \dots, m$ 。



$$\operatorname{argmin} \frac{1}{m} \sum_{i=1}^m (\text{distance between } \mathbf{x}_i \text{ and } k\text{-dimensional subspace spanned by } \mathbf{v}_1, \dots, \mathbf{v}_k)^2$$

$$\operatorname{argmax} \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

本讲中的目标函数

$$\frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

近似误差

最初问题：  
最小化近似误差

## 近似误差



分析思路：用矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值刻画结果

近似误差

$$\frac{1}{m} \sum_{i=1}^m \|x_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\langle x_i, v_1 \rangle^2 + \cdots + \langle x_i, v_k \rangle^2)$$



## 近似误差



分析思路：用矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值刻画结果

近似误差

$$\frac{1}{m} \sum_{i=1}^m \|x_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\langle x_i, v_1 \rangle^2 + \cdots + \langle x_i, v_k \rangle^2)$$

定义 $\mathbf{V}$ 为由列向量 $v_1, \dots, v_k$ 构成的 $n \times k$ 矩阵



# 近似误差



分析思路：用矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值刻画结果

近似误差

$$\frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\underbrace{\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2}_{\text{标量}} + \cdots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

定义 $\mathbf{V}$ 为由列向量 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 构成的 $n \times k$ 矩阵

$$= \frac{1}{m} \sum_{i=1}^m \underbrace{\|\mathbf{x}_i\|_2^2}_{n \times 1 \text{ 列向量}} - \frac{1}{m} \sum_{i=1}^m \underbrace{\|\mathbf{V}^T \mathbf{x}_i\|_2^2}_{k \times 1 \text{ 列向量}}$$

# 近似误差



分析思路：用矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值刻画结果


近似误差

$$\frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$


定义 $\mathbf{V}$ 为由列向量 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 构成的 $n \times k$ 矩阵

$$= \frac{1}{m} \sum_{i=1}^m \underbrace{\|\mathbf{x}_i\|_2^2}_{n \times 1 \text{ 列向量}} - \frac{1}{m} \sum_{i=1}^m \underbrace{\|\mathbf{V}^T \mathbf{x}_i\|_2^2}_{k \times 1 \text{ 列向量}}$$

分析 $n \times n$ 矩阵 $\mathbf{X}^T \mathbf{X}$



$n \times m$ 矩阵 $\mathbf{X}^T$



$m \times n$ 矩阵 $\mathbf{X}$

$$\sum_{i=1}^m \|\mathbf{x}_i\|_2^2 = \text{tr}(\mathbf{X}^T \mathbf{X})$$

(展开 $\mathbf{X}^T \mathbf{X}$ 中对角线元素可得)

迹：方阵对角线上元素之和

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}$$

# 近似误差



分析思路：用矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值刻画结果

近似误差

$$\frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \cdots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

$$\begin{aligned} &= \frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m \|\mathbf{V}^T \mathbf{x}_i\|_2^2 \\ &= \frac{1}{m} \text{tr}(\underbrace{\mathbf{X}^T \mathbf{X}}_{n \times n \text{ 方阵}}) - \frac{1}{m} \text{tr}(\underbrace{\mathbf{V}^T \mathbf{X}^T \mathbf{X} \mathbf{V}}_{k \times k \text{ 方阵}}) \end{aligned}$$

*(Note: In the original image, the terms  $\mathbf{x}_i$  in the second term of the first equation and  $\mathbf{V}^T \mathbf{x}_i$  in the second equation are underlined.)*

定义 $\mathbf{V}$ 为由列向量 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 构成的 $n \times k$ 矩阵

Given any  $n \times n$  real or complex matrix  $\mathbf{A}$ , there is

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i$$

# 近似误差



分析思路：用矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值刻画结果

近似误差

$$\frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

$$= \frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m \|\mathbf{V}^T \mathbf{x}_i\|_2^2$$

$$= \frac{1}{m} \text{tr}(\mathbf{X}^T \mathbf{X}) - \frac{1}{m} \text{tr}(\mathbf{V}^T \mathbf{X}^T \mathbf{X} \mathbf{V})$$

$n \times n$ 方阵       $k \times k$ 方阵

$$= \frac{1}{m} \sum_{i=1}^n \lambda_i - \frac{1}{m} \text{tr}(\mathbf{V}^T \mathbf{Q} \mathbf{D} \mathbf{Q}^T \mathbf{V})$$

定义 $\mathbf{V}$ 为由列向量 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 构成的 $n \times k$ 矩阵

Given any  $n \times n$  real or complex matrix  $\mathbf{A}$ , there is

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i$$

$$\mathbf{V}^T \mathbf{Q} \mathbf{D} \mathbf{Q}^T \mathbf{V} \text{ 为 } \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_k \end{bmatrix}$$

可利用标准正交向量组性质得

$k \times k$ 方阵，不是矩阵 $\mathbf{D}$



# 近似误差



分析思路：用矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值刻画结果

近似误差

$$\frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \cdots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2)$$

定义 $\mathbf{V}$ 为由列向量 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 构成的 $n \times k$ 矩阵

$$= \frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 - \frac{1}{m} \sum_{i=1}^m \|\mathbf{V}^T \mathbf{x}_i\|_2^2$$

$$= \frac{1}{m} \text{tr}(\mathbf{X}^T \mathbf{X}) - \frac{1}{m} \text{tr}(\mathbf{V}^T \mathbf{X}^T \mathbf{X} \mathbf{V})$$

$n \times n$ 方阵       $k \times k$ 方阵

$$= \frac{1}{m} \sum_{i=1}^n \lambda_i - \frac{1}{m} \text{tr}(\mathbf{V}^T \mathbf{Q} \mathbf{D} \mathbf{Q}^T \mathbf{V})$$

$$= \frac{1}{m} \sum_{i=1}^n \lambda_i - \frac{1}{m} \sum_{i=1}^k \lambda_i$$

$$= \frac{1}{m} \sum_{i=k+1}^n \lambda_i$$

# 近似误差

## 主成分分析 (Principal Component Analysis, PCA)

给定  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$  及维数  $k \geq 1$ , 求标准正交向量组  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$  从而最大化

$$\frac{1}{m} \sum_{i=1}^m (\langle \mathbf{x}_i, \mathbf{v}_1 \rangle^2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_k \rangle^2).$$

## 主成分分析问题的最优解

最大化目标函数的  $\mathbf{v}_1^*, \dots, \mathbf{v}_k^*$  为矩阵  $\mathbf{X}^T \mathbf{X}$  的最大的  $k$  个特征值对应的  $k$  个单位特征向量。

近似误差

$$\frac{1}{m} \sum_{i=1}^m (\text{distance between } \mathbf{x}_i \text{ and } k - \text{dimensional subspace spanned by } \mathbf{v}_1, \dots, \mathbf{v}_k)^2$$

等于矩阵  $\mathbf{X}^T \mathbf{X}$  的最小的  $n - k$  个特征值之和

该值越小, 近似误差越小



# 近似误差

近似误差


$$\frac{1}{m} \sum_{i=1}^m (\text{distance between } x_i \text{ and } k - \text{dimensional subspace spanned by } v_1, \dots, v_k)^2$$

等于矩阵 $X^T X$ 的最小的 $n - k$ 个特征值之和

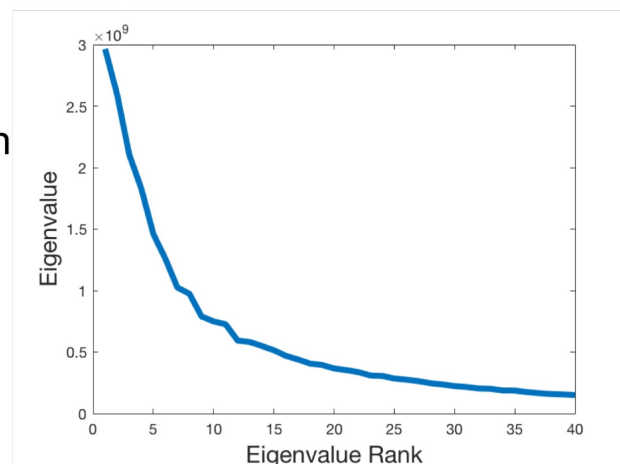
该值越小，近似误差越小

如有60000张

784 dimensional vectors



eigendecomposition



# 近似误差

近似误差


$$\frac{1}{m} \sum_{i=1}^m (\text{distance between } \mathbf{x}_i \text{ and } k - \text{dimensional subspace spanned by } \mathbf{v}_1, \dots, \mathbf{v}_k)^2$$

等于矩阵 $\mathbf{X}^T \mathbf{X}$ 的最小的 $n - k$ 个特征值之和


该值越小，近似误差越小

如有60000张

784 dimensional vectors



eigendecomposition



# 主成分分析

## 幂迭代法



# 幂迭代法

---

主成分分析问题的最优解

最大化目标函数的 $v_1^*, \dots, v_k^*$ 为矩阵 $\mathbf{X}^T \mathbf{X}$ 的最大的 $k$ 个特征值对应的 $k$ 个单位特征向量。

如何算矩阵的特征向量?

- (1) 奇异值分解 (Singular Value Decomposition) (下一讲内容)
- (2) 幂迭代法 (Power Iteration Method)



# 幂迭代法

计算矩阵最大特征值对应的单位特征向量（即第一主成分）：

## 幂迭代法

- 0 随机选择一个单位向量  $\mathbf{u}_0 \in \mathbb{R}^n$ ; 计算  $\mathbf{A} = \mathbf{X}^T \mathbf{X}$
- 1 for  $i=1, 2, \dots$
- 2 计算  $\mathbf{u}_i = \mathbf{A} \mathbf{u}_{i-1}$
- 3 检查终止条件：若  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|} \approx \frac{\mathbf{u}_{i-1}}{\|\mathbf{u}_{i-1}\|}$ ，结束算法、输出  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$

确保是单位向量

为什么可以输出  $\mathbf{A}$  的最大特征值对应的单位特征向量？

分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义



## 幂迭代法的几何解释

分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

先考虑特殊情况：假设  $\mathbf{A}$  是对角矩阵 
$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$$
 且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$





# 幂迭代法的几何解释


分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

先考虑特殊情况：假设  $\mathbf{A}$  是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

若矩阵  $\mathbf{A}$  为  $\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$  设  $\mathbf{u}_0 = (x, y)^T$

$\mathbf{u}_0 = (x, y)^T$  有可能位置：实线圆

$\mathbf{u}_1 = (2x, y)^T$  所有可能位置：虚线椭圆



# 幂迭代法的几何解释

分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义


先考虑特殊情况：假设  $\mathbf{A}$  是对角矩阵  $\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$  且满足  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

若矩阵  $\mathbf{A}$  为  $\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$  设  $\mathbf{u}_0 = (x, y)^T$

$\mathbf{u}_0 = (x, y)^T$  有可能位置：实线圆

$\mathbf{u}_1 = (2x, y)^T$  所有可能位置：虚线椭圆

特征值2对应的单位特征向量为  $(1, 0)^T$  或  $(-1, 0)^T$



## 幂迭代法的几何解释

分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

再考虑一般情况： $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ ， $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且 } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

若矩阵 $\mathbf{A}$ 为  $\begin{pmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix} = \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}}_{\text{rotate back } 45^\circ} \cdot \underbrace{\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}}_{\text{stretch}} \cdot \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}}_{\text{rotate clockwise } 45^\circ}$  此 $\mathbf{A}$ 仅为示例，未必由 $\mathbf{X}^T \mathbf{X}$ 得到

# 幂迭代法的几何解释



分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

再考虑一般情况： $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ ， $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且 } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

若矩阵 $\mathbf{A}$ 为  $\begin{pmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix} = \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}}_{\text{rotate back } 45^\circ} \cdot \underbrace{\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}}_{\text{stretch}} \cdot \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}}_{\text{rotate clockwise } 45^\circ}$

此 $\mathbf{A}$ 仅为示例，未必由 $\mathbf{X}^T \mathbf{X}$ 得到



$$(1, 0)^T \rightarrow \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)^T \rightarrow \left(\sqrt{2}, -\frac{1}{\sqrt{2}}\right)^T \rightarrow \left(\frac{3}{2}, \frac{1}{2}\right)^T$$

# 幂迭代法的几何解释



分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

再考虑一般情况： $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ ， $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且 } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

若矩阵 $\mathbf{A}$ 为  $\begin{pmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix} = \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}}_{\text{rotate back } 45^\circ} \cdot \underbrace{\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}}_{\text{stretch}} \cdot \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}}_{\text{rotate clockwise } 45^\circ}$

此 $\mathbf{A}$ 仅为示例，未必由 $\mathbf{X}^T \mathbf{X}$ 得到



$$(1, 0)^T \rightarrow \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)^T \rightarrow \left(\sqrt{2}, -\frac{1}{\sqrt{2}}\right)^T \rightarrow \left(\frac{3}{2}, \frac{1}{2}\right)^T$$



特征值2对应的单位特征向量为 $\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^T$  或  $\left(-\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)^T$

# 幂迭代法的几何解释

分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

再考虑一般情况： $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ ， $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且 } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$





以上仅分析了 $i = 1$ 的情况， $i > 1$ 时？

# 幂迭代法的几何解释

分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

再考虑一般情况： $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ ， $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且 } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$



以上仅分析了 $i = 1$ 的情况， $i > 1$ 时？



可证明，若 $\mathbf{A} = \mathbf{QDQ}^T$ ，有 $\mathbf{A}^i = \mathbf{QD}^i\mathbf{Q}^T$ （用正交矩阵的性质 $\mathbf{Q}^T\mathbf{Q} = \mathbf{I}$ ）

# 幂迭代法的几何解释

分析  $\mathbf{u}_i = \mathbf{A}^i \mathbf{u}_0$  的几何意义

再考虑一般情况： $\mathbf{A}$ 可写成 $\mathbf{QDQ}^T$ ， $\mathbf{Q}$ 是正交矩阵、 $\mathbf{D}$ 是

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \quad \text{且 } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$



以上仅分析了 $i = 1$ 的情况， $i > 1$ 时？

可证明，若 $\mathbf{A} = \mathbf{QDQ}^T$ ，有 $\mathbf{A}^i = \mathbf{QD}^i\mathbf{Q}^T$ （用正交矩阵的性质 $\mathbf{Q}^T\mathbf{Q} = \mathbf{I}$ ）

当 $i$ 很大时， $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$ 将趋近于 $\mathbf{A}$ 的最大特征值对应的向量



# 幂迭代法的证明

计算矩阵最大特征值对应的单位特征向量（即第一主成分）：

## 幂迭代法

- 0 随机选择一个单位向量  $\mathbf{u}_0 \in \mathbb{R}^n$ ; 计算  $\mathbf{A} = \mathbf{X}^T \mathbf{X}$
- 1 for  $i=1, 2, \dots$
- 2 计算  $\mathbf{u}_i = \mathbf{A} \mathbf{u}_{i-1}$
- 3 检查终止条件：若  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|} \approx \frac{\mathbf{u}_{i-1}}{\|\mathbf{u}_{i-1}\|}$ ，结束算法、输出  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$

用  $\mathbf{q}_1$  表示  $\mathbf{A}$  的最大特征值对应的单位特征向量，如何证明当  $i$  很大时  $\left\| \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}, \mathbf{q}_1 \right\|$  趋近于1？



## 幂迭代法的证明



证明思路:

- (1) 用  $q_1, q_2, \dots, q_n$  表示  $A^i u_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $q_1$  表示  $A$  的最大特征值对应的单位特征向量，证明当  $i$  很大时  $\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle$  趋近于 1

用  $q_1, q_2, \dots, q_n \in \mathbb{R}^n$  表示  $A$  的  $n$  个单位特征向量（对应  $\lambda_1 \geq \lambda_2 \geq \dots \lambda_n$ ），是一组标准正交向量



## 幂迭代法的证明



证明思路:

- (1) 用  $q_1, q_2, \dots, q_n$  表示  $A^i u_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $q_1$  表示  $A$  的最大特征值对应的单位特征向量，证明当  $i$  很大时  $\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle$  趋近于 1

用  $q_1, q_2, \dots, q_n \in \mathbb{R}^n$  表示  $A$  的  $n$  个单位特征向量（对应  $\lambda_1 \geq \lambda_2 \geq \dots \lambda_n$ ），是一组标准正交向量

因为  $u_0 \in \mathbb{R}^n$ ，一定可将其写成  $q_1, q_2, \dots, q_n$  的线性组合，将结果记为  $u_0 = \sum_{j=1}^n c_j q_j$

## 幂迭代法的证明



证明思路:

- (1) 用  $q_1, q_2, \dots, q_n$  表示  $A^i u_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $q_1$  表示  $A$  的最大特征值对应的单位特征向量，证明当  $i$  很大时  $\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle$  趋近于 1

用  $q_1, q_2, \dots, q_n \in \mathbb{R}^n$  表示  $A$  的  $n$  个单位特征向量（对应  $\lambda_1 \geq \lambda_2 \geq \dots \lambda_n$ ），是一组标准正交向量

因为  $u_0 \in \mathbb{R}^n$ ，一定可将其写成  $q_1, q_2, \dots, q_n$  的线性组合，将结果记为  $u_0 = \sum_{j=1}^n c_j q_j$

可以将  $A$  写成  $QDQ^T$ ，其中  $Q$  的各列是  $q_1, q_2, \dots, q_n$ ， $D$  是由  $\lambda_1, \lambda_2, \dots, \lambda_n$  确定的对角矩阵

## 幂迭代法的证明



证明思路:

- (1) 用  $q_1, q_2, \dots, q_n$  表示  $A^i u_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $q_1$  表示  $A$  的最大特征值对应的单位特征向量，证明当  $i$  很大时  $\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle$  趋近于 1

用  $q_1, q_2, \dots, q_n \in \mathbb{R}^n$  表示  $A$  的  $n$  个单位特征向量（对应  $\lambda_1 \geq \lambda_2 \geq \dots \lambda_n$ ），是一组标准正交向量

因为  $u_0 \in \mathbb{R}^n$ ，一定可将其写成  $q_1, q_2, \dots, q_n$  的线性组合，将结果记为  $u_0 = \sum_{j=1}^n c_j q_j$

可以将  $A$  写成  $QDQ^T$ ，其中  $Q$  的各列是  $q_1, q_2, \dots, q_n$ ， $D$  是由  $\lambda_1, \lambda_2, \dots, \lambda_n$  确定的对角矩阵

根据前面结果，有  $A^i = QD^iQ^T$



## 幂迭代法的证明



证明思路:

- (1) 用  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$  表示  $\mathbf{A}^i \mathbf{u}_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $\mathbf{q}_1$  表示  $\mathbf{A}$  的最大特征值对应的单位特征向量，证明当  $i$  很大时  $\left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle$  趋近于 1

用  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n \in \mathbb{R}^n$  表示  $\mathbf{A}$  的  $n$  个单位特征向量（对应  $\lambda_1 \geq \lambda_2 \geq \dots \lambda_n$ ），是一组标准正交向量

因为  $\mathbf{u}_0 \in \mathbb{R}^n$ ，一定可将其写成  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$  的线性组合，将结果记为  $\mathbf{u}_0 = \sum_{j=1}^n c_j \mathbf{q}_j$

可以将  $\mathbf{A}$  写成  $\mathbf{QDQ}^T$ ，其中  $\mathbf{Q}$  的各列是  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$ ， $\mathbf{D}$  是由  $\lambda_1, \lambda_2, \dots, \lambda_n$  确定的对角矩阵

根据前面结果，有  $\mathbf{A}^i = \mathbf{QD}^i \mathbf{Q}^T$

$$\text{可以计算 } \mathbf{A}^i \mathbf{u}_0 = \mathbf{QD}^i \mathbf{Q}^T \mathbf{u}_0 = \mathbf{QD}^i \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} = \mathbf{Q} \begin{bmatrix} c_1 \lambda_1^i \\ c_2 \lambda_2^i \\ \vdots \\ c_n \lambda_n^i \end{bmatrix} = \sum_{j=1}^n \lambda_j^i c_j \mathbf{q}_j$$

## 幂迭代法的证明



证明思路:

- (1) 用  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$  表示  $\mathbf{A}^i \mathbf{u}_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $\mathbf{q}_1$  表示  $\mathbf{A}$  的最大特征值对应的单位特征向量，证明当  $i$  很大时  $\left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle$  趋近于 1

用  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n \in \mathbb{R}^n$  表示  $\mathbf{A}$  的  $n$  个单位特征向量（对应  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ），是一组标准正交向量

因为  $\mathbf{u}_0 \in \mathbb{R}^n$ ，一定可将其写成  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$  的线性组合，将结果记为  $\mathbf{u}_0 = \sum_{j=1}^n c_j \mathbf{q}_j$

可以将  $\mathbf{A}$  写成  $\mathbf{QDQ}^T$ ，其中  $\mathbf{Q}$  的各列是  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$ ， $\mathbf{D}$  是由  $\lambda_1, \lambda_2, \dots, \lambda_n$  确定的对角矩阵

根据前面结果，有  $\mathbf{A}^i = \mathbf{QD}^i \mathbf{Q}^T$

$$\text{可以计算 } \mathbf{A}^i \mathbf{u}_0 = \mathbf{QD}^i \mathbf{Q}^T \mathbf{u}_0 = \mathbf{QD}^i \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} = \mathbf{Q} \begin{bmatrix} c_1 \lambda_1^i \\ c_2 \lambda_2^i \\ \vdots \\ c_n \lambda_n^i \end{bmatrix} = \sum_{j=1}^n \lambda_j^i c_j \mathbf{q}_j$$

$$\text{可以计算 } \|\mathbf{A}^i \mathbf{u}_0\| = \sqrt{(\mathbf{A}^i \mathbf{u}_0)^T \mathbf{A}^i \mathbf{u}_0} = \sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2} \text{ 且 } \langle \mathbf{A}^i \mathbf{u}_0, \mathbf{q}_1 \rangle = \lambda_1^i c_1$$

$$\text{得到 } \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle = \frac{\lambda_1^i c_1}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}}$$

## 幂迭代法的证明



证明思路:

- (1) 用  $q_1, q_2, \dots, q_n$  表示  $A^i u_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $q_1$  表示  $A$  的最大特征值对应的单位特征向量, 证明当  $i$  很大时  $\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle$  趋近于 1

$$\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle = \frac{\lambda_1^i |c_1|}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}} = \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \sum_{j \geq 2}^n (\lambda_j^i c_j)^2}}$$

利用  $\lambda_1$  是最大特征值



## 幂迭代法的证明



证明思路:

- (1) 用  $q_1, q_2, \dots, q_n$  表示  $A^i u_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $q_1$  表示  $A$  的最大特征值对应的单位特征向量，证明当  $i$  很大时  $\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle$  趋近于 1

$$\begin{aligned} \left| \left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle \right| &= \frac{\lambda_1^i |c_1|}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}} = \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \sum_{j \geq 2}^n (\lambda_j^i c_j)^2}} \\ &\geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i} \sum_{j \geq 2}^n (c_j)^2}} \end{aligned}$$

放缩成关于  $\lambda_1^i$  与  $\lambda_2^i$  的式子

## 幂迭代法的证明



证明思路:

- (1) 用  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$  表示  $\mathbf{A}^i \mathbf{u}_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $\mathbf{q}_1$  表示  $\mathbf{A}$  的最大特征值对应的单位特征向量, 证明当  $i$  很大时  $\left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle$  趋近于 1

$$\begin{aligned} \left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| &= \frac{\lambda_1^i |c_1|}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}} = \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \sum_{j \geq 2}^n (\lambda_j^i c_j)^2}} \\ &\geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i} \sum_{j \geq 2}^n (c_j)^2}} \geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i}}} \end{aligned}$$

利用  $\|\mathbf{u}_0\| = \|\sum_{j=1}^n c_j \mathbf{q}_j\| = \sqrt{(\sum_{j=1}^n c_j \mathbf{q}_j)^T \sum_{j=1}^n c_j \mathbf{q}_j} = 1$  可得  $\sum_{j \geq 2}^n (c_j)^2 \leq \sum_{j \geq 1}^n (c_j)^2 = 1$

## 幂迭代法的证明



证明思路:

- (1) 用  $q_1, q_2, \dots, q_n$  表示  $A^i u_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $q_1$  表示  $A$  的最大特征值对应的单位特征向量, 证明当  $i$  很大时  $\left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle$  趋近于 1

$$\begin{aligned} \left| \left\langle \frac{A^i u_0}{\|A^i u_0\|}, q_1 \right\rangle \right| &= \frac{\lambda_1^i |c_1|}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}} = \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \sum_{j \geq 2}^n (\lambda_j^i c_j)^2}} \\ &\geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i} \sum_{j \geq 2}^n (c_j)^2}} \geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i}}} \geq \frac{\lambda_1^i |c_1|}{\lambda_1^i |c_1| + \lambda_2^i} \end{aligned}$$



## 幂迭代法的证明



证明思路:

- (1) 用  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$  表示  $\mathbf{A}^i \mathbf{u}_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $\mathbf{q}_1$  表示  $\mathbf{A}$  的最大特征值对应的单位特征向量, 证明当  $i$  很大时  $\left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle$  趋近于 1

$$\begin{aligned} \left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| &= \frac{\lambda_1^i |c_1|}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}} = \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \sum_{j \geq 2}^n (\lambda_j^i c_j)^2}} \\ &\geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i} \sum_{j \geq 2}^n (c_j)^2}} \geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i}}} \geq \frac{\lambda_1^i |c_1|}{\lambda_1^i |c_1| + \lambda_2^i} \end{aligned}$$

易得:

$$\left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| \geq \frac{\lambda_1^i |c_1|}{\lambda_1^i |c_1| + \lambda_2^i} = \frac{1}{1 + \frac{\lambda_2^i}{\lambda_1^i |c_1|}} \geq 1 - \frac{1}{|c_1|} \left( \frac{\lambda_2}{\lambda_1} \right)^i$$

## 幂迭代法的证明



证明思路:

- (1) 用  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$  表示  $\mathbf{A}^i \mathbf{u}_0$
- (2) 用  $\lambda_1, \lambda_2, \dots$  刻画目标数值

用  $\mathbf{q}_1$  表示  $\mathbf{A}$  的最大特征值对应的单位特征向量, 证明当  $i$  很大时  $\left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle$  趋近于 1

$$\begin{aligned} \left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| &= \frac{\lambda_1^i |c_1|}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}} = \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \sum_{j \geq 2}^n (\lambda_j^i c_j)^2}} \\ &\geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i} \sum_{j \geq 2}^n (c_j)^2}} \geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i}}} \geq \frac{\lambda_1^i |c_1|}{\lambda_1^i |c_1| + \lambda_2^i} \end{aligned}$$

易得:

$$\left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| \geq \frac{\lambda_1^i |c_1|}{\lambda_1^i |c_1| + \lambda_2^i} = \frac{1}{1 + \frac{\lambda_2^i}{\lambda_1^i |c_1|}} \geq 1 - \frac{1}{|c_1|} \left( \frac{\lambda_2}{\lambda_1} \right)^i$$

例如, 当  $\mathbf{u}_0$  恰好为其它单位特征向量  $\mathbf{q}_j (j \neq 1)$  时, 幂迭代法无法收敛到  $\mathbf{q}_1$

$c_1$  是随机向量  $\mathbf{u}_0$  在  $\mathbf{q}_1$  方向的投影长度 ( $\mathbf{u}_0 = \sum_{j=1}^n c_j \mathbf{q}_j$ )

可假设  $\mathbf{u}_0$  各元素都分别依标准正态分布随机独立取值 (并标准化), 由此可得以概率描述的  $|c_1|$  的下界

若有  $\frac{\lambda_2}{\lambda_1} < 1$ , 可知随  $i$  增大,  $\left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right|$  的下界趋近于 1。此外,  $\left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| = |\cos \text{夹角}| \leq 1$

## 幂迭代法的证明

用 $\mathbf{q}_1$ 表示 $\mathbf{A}$ 的最大特征值对应的单位特征向量，证明当 $i$ 很大时 $\left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle$ 趋近于1

$$\begin{aligned} \left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| &= \frac{\lambda_1^i |c_1|}{\sqrt{\sum_{j=1}^n (\lambda_j^i c_j)^2}} = \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \sum_{j \geq 2}^n (\lambda_j^i c_j)^2}} \\ &\geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i} \sum_{j \geq 2}^n (c_j)^2}} \geq \frac{\lambda_1^i |c_1|}{\sqrt{(\lambda_1^i c_1)^2 + \lambda_2^{2i}}} \geq \frac{\lambda_1^i |c_1|}{\lambda_1^i |c_1| + \lambda_2^i} \end{aligned}$$

易得：

$$\left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| \geq \frac{\lambda_1^i |c_1|}{\lambda_1^i |c_1| + \lambda_2^i} = \frac{1}{1 + \frac{\lambda_2^i}{\lambda_1^i |c_1|}} \geq 1 - \frac{1}{|c_1|} \left( \frac{\lambda_2}{\lambda_1} \right)^i$$

实际计算中，若 $\frac{\lambda_2}{\lambda_1}$ 接近1，  
算法收敛速度很慢

$c_1$ 是随机向量 $\mathbf{u}_0$ 在 $\mathbf{q}_1$ 方向的投影长度 ( $\mathbf{u}_0 = \sum_{j=1}^n c_j \mathbf{q}_j$ )

可假设 $\mathbf{u}_0$ 各元素都分别依标准正态分布随机独立取值（并标准化），由此可得以概率描述的 $|c_1|$ 的下界

若有 $\frac{\lambda_2}{\lambda_1} < 1$ ，可知随 $i$ 增大， $\left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right|$ 的下界趋近于1。此外， $\left| \left\langle \frac{\mathbf{A}^i \mathbf{u}_0}{\|\mathbf{A}^i \mathbf{u}_0\|}, \mathbf{q}_1 \right\rangle \right| = |\cos \text{夹角}| \leq 1$

# 幂迭代法

计算矩阵最大特征值对应的单位特征向量（即第一主成分）：

## 幂迭代法

- 0 随机选择一个单位向量  $\mathbf{u}_0 \in \mathbb{R}^n$ ; 计算  $\mathbf{A} = \mathbf{X}^T \mathbf{X}$
- 1 for  $i=1, 2, \dots$
- 2 计算  $\mathbf{u}_i = \mathbf{A} \mathbf{u}_{i-1}$
- 3 检查终止条件：若  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|} \approx \frac{\mathbf{u}_{i-1}}{\|\mathbf{u}_{i-1}\|}$ ，结束算法、输出  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$

在实际应用中，为加快计算速度、减少矩阵乘以向量的次数，经常先计算  $\mathbf{A}^1, \mathbf{A}^2, \mathbf{A}^4, \mathbf{A}^8, \dots$ ，然后得到  $\mathbf{A}^1 \mathbf{u}_0, \mathbf{A}^2 \mathbf{u}_0, \mathbf{A}^4 \mathbf{u}_0, \mathbf{A}^8 \mathbf{u}_0, \dots$ 。



# 幂迭代法

计算矩阵最大特征值对应的单位特征向量（即第一主成分）：

## 幂迭代法

- 0 随机选择一个单位向量  $\mathbf{u}_0 \in \mathbb{R}^n$ ; 计算  $\mathbf{A} = \mathbf{X}^T \mathbf{X}$
- 1 for  $i=1, 2, \dots$
- 2 计算  $\mathbf{u}_i = \mathbf{A} \mathbf{u}_{i-1}$
- 3 检查终止条件：若  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|} \approx \frac{\mathbf{u}_{i-1}}{\|\mathbf{u}_{i-1}\|}$ ，结束算法、输出  $\frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$

如何计算前 $k$ 个主成分？





# 幂迭代法

计算前 $k$ 个主成分：

➤ 用幂迭代法计算第一主成分，记为 $\mathbf{v}_1$

➤ 处理数据 $\mathbf{X}$ ：

$$\begin{bmatrix} \text{—} & \mathbf{x}_1^T & \text{—} \\ \text{—} & \mathbf{x}_2^T & \text{—} \\ & \vdots & \\ \text{—} & \mathbf{x}_m^T & \text{—} \end{bmatrix} \mapsto \begin{bmatrix} \text{—} & (\mathbf{x}_1^T - \langle \mathbf{x}_1, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ \text{—} & (\mathbf{x}_2^T - \langle \mathbf{x}_2, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ & \vdots & \\ \text{—} & (\mathbf{x}_m^T - \langle \mathbf{x}_m, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \end{bmatrix}$$

剔除数据中已经由第一主成分表征的数据间的差异

➤ 对新的 $\mathbf{X}^T \mathbf{X}$ 计算前 $k - 1$ 个主成分



# 幂迭代法

计算前 $k$ 个主成分：

➤ 用幂迭代法计算第一主成分，记为 $\mathbf{v}_1$

➤ 处理数据 $\mathbf{X}$ ：

$$\begin{bmatrix} \text{—} & \mathbf{x}_1^T & \text{—} \\ \text{—} & \mathbf{x}_2^T & \text{—} \\ & \vdots & \\ \text{—} & \mathbf{x}_m^T & \text{—} \end{bmatrix} \mapsto \begin{bmatrix} \text{—} & (\mathbf{x}_1^T - \langle \mathbf{x}_1, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ \text{—} & (\mathbf{x}_2^T - \langle \mathbf{x}_2, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ & \vdots & \\ \text{—} & (\mathbf{x}_m^T - \langle \mathbf{x}_m, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \end{bmatrix}$$

剔除数据中已经由第一主成分表征的数据间的差异

➤ 对新的 $\mathbf{X}^T \mathbf{X}$ 计算前 $k - 1$ 个主成分

如何理解新 $\mathbf{X}^T \mathbf{X}$ 的前 $k - 1$ 个主成分即为原 $\mathbf{X}^T \mathbf{X}$ 的第二至第 $k$ 个主成分？



# 幂迭代法

计算前 $k$ 个主成分：

➤ 用幂迭代法计算第一主成分，记为 $\mathbf{v}_1$

➤ 处理数据 $\mathbf{X}$ ：

$$\begin{bmatrix} \text{—} & \mathbf{x}_1^T & \text{—} \\ \text{—} & \mathbf{x}_2^T & \text{—} \\ & \vdots & \\ \text{—} & \mathbf{x}_m^T & \text{—} \end{bmatrix} \mapsto \begin{bmatrix} \text{—} & (\mathbf{x}_1^T - \langle \mathbf{x}_1, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ \text{—} & (\mathbf{x}_2^T - \langle \mathbf{x}_2, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ & \vdots & \\ \text{—} & (\mathbf{x}_m^T - \langle \mathbf{x}_m, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \end{bmatrix}$$

剔除数据中已经由第一主成分表征的数据间的差异

➤ 对新的 $\mathbf{X}^T \mathbf{X}$ 计算前 $k - 1$ 个主成分

如何理解新 $\mathbf{X}^T \mathbf{X}$ 的前 $k - 1$ 个主成分即为原 $\mathbf{X}^T \mathbf{X}$ 的第二至第 $k$ 个主成分？

将 $\mathbf{X}^T \mathbf{X}$ 的所有主成分记为 $\mathbf{v}_1, \dots, \mathbf{v}_n$ ，它们构成标准正交向量组

对数据 $\mathbf{x}_i$ ，由于 $\mathbf{x}_i \in \mathbb{R}^n$ ，可将其写为 $n$ 维空间的 $n$ 个标准正交向量的线性组合：

$$\mathbf{x}_i = \sum_{j=1}^n \langle \mathbf{x}_i, \mathbf{v}_j \rangle \mathbf{v}_j = \langle \mathbf{x}_i, \mathbf{v}_1 \rangle \mathbf{v}_1 + \langle \mathbf{x}_i, \mathbf{v}_2 \rangle \mathbf{v}_2 + \dots + \langle \mathbf{x}_i, \mathbf{v}_n \rangle \mathbf{v}_n$$

# 幂迭代法

计算前 $k$ 个主成分:

➤ 用幂迭代法计算第一主成分, 记为 $v_1$

➤ 处理数据 $\mathbf{X}$ : 
$$\begin{bmatrix} \text{—} & \mathbf{x}_1^T & \text{—} \\ \text{—} & \mathbf{x}_2^T & \text{—} \\ & \vdots & \\ \text{—} & \mathbf{x}_m^T & \text{—} \end{bmatrix} \mapsto \begin{bmatrix} \text{—} & (\mathbf{x}_1^T - \langle \mathbf{x}_1, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ \text{—} & (\mathbf{x}_2^T - \langle \mathbf{x}_2, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \\ & \vdots & \\ \text{—} & (\mathbf{x}_m^T - \langle \mathbf{x}_m, \mathbf{v}_1 \rangle \mathbf{v}_1^T) & \text{—} \end{bmatrix}$$

剔除数据中已经由第一主成分表征的数据间的差异

➤ 对新的 $\mathbf{X}^T \mathbf{X}$ 计算前 $k-1$ 个主成分

如何理解新 $\mathbf{X}^T \mathbf{X}$ 的前 $k-1$ 个主成分即为原 $\mathbf{X}^T \mathbf{X}$ 的第二至第 $k$ 个主成分?

将 $\mathbf{X}^T \mathbf{X}$ 的所有主成分记为 $v_1, \dots, v_n$ , 它们构成标准正交向量组

对数据 $x_i$ , 由于 $x_i \in \mathbb{R}^n$ , 可将其写为 $n$ 维空间的 $n$ 个标准正交向量的线性组合:

$$x_i = \sum_{j=1}^n \langle x_i, v_j \rangle v_j = \langle x_i, v_1 \rangle v_1 + \langle x_i, v_2 \rangle v_2 + \dots + \langle x_i, v_n \rangle v_n$$

# $k$ 的选择


在应用中如何选择 $k$ ? 即找到多少个主成分?

- 若目的是数据可视化: 如 $k = 2, k = 3$
- 若目的是数据压缩: 需考虑近似精度的要求, 一般要确保剩余的 $n - k$ 个特征值都比较小

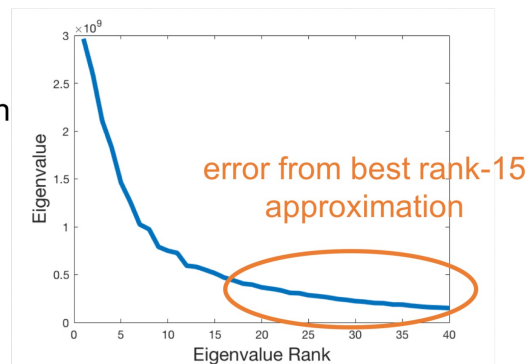
如考虑确保 
$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^n \lambda_i} \geq (1 - \epsilon)$$

回顾: 近似误差为  $\frac{1}{m} \sum_{i=k+1}^n \lambda_i$

784 dimensional vectors



eigendecomposition



# 本讲小结

---



主成分的代数性质



求解主成分的方法

# 主要参考资料

---

Tim Roughgarden and Gregory Valiant <CS 168 - The Modern Algorithmic Toolbox> Lecture Notes

Cameron Musco <COMPSCI 514 - Algorithms for Data Science> Slides

# 谢谢!

